

Прогнозирование выручки фильмов с использованием моделей машинного обучения

Разработано: Цветков Артём Денисович

Организация: СГТУ им. Гагарина Ю.А.

Направление: М-ПИНФ-21

Аннотация

В современной киноиндустрии точное прогнозирование доходов фильма имеет ключевое значение для максимизации прибыльности. Данный проект направлен на разработку модели машинного обучения для прогнозирования выручки фильма на основе входных признаков, таких как название фильма, возрастной рейтинг, жанр, год выхода, рейтинг IMDb, количество голосов зрителей, режиссёр, сценарист, ведущий актёрский состав, страна производства, бюджет, производственная компания и длительность фильма.

С помощью структурированной методологии, включающей сбор данных, предварительную обработку, анализ, выбор модели, оценку и улучшение, строится устойчивая прогностическая модель. Были обучены и протестированы линейная регрессия, деревья решений, случайный лес, bagging, XGBoost и Gradient Boosting. Стратегии улучшения модели включают настройку гиперпараметров и кросс-валидацию. Полученная модель показывает перспективную точность и способность к обобщению, помогая принимать более обоснованные решения в киноиндустрии для максимизации прибыли.

I. Введение

A. Мотивация

Представим, что вы являетесь кинорежиссёром или руководителем кинокомпании, и перед вами стоит важный вопрос: что делает фильм блокбастером или, наоборот, провалом?

Можно предположить, что успех зависит от известности актёров, видения режиссёра, бюджета производства или жанра истории.

Также можно считать, что всё определяется качеством повествования, которое привлекает аудиторию и получает высокие оценки. Однако ответ не является простым и однозначным.

На выручку фильма влияет множество факторов, и точная комбинация этих факторов до конца не определена. Поэтому была разработана модель машинного обучения, которая выявляет наиболее важные факторы кассового успеха на основе анализа реальных данных о фильмах, произведённых в разных странах. Такая модель позволяет создателям фильмов принимать более информированные решения и оптимизировать производство для повышения прибыли и популярности.

B. Обоснование

Предполагается, что некоторые параметры имеют большее значение для прогнозирования выручки фильма, чем другие. В частности, значимыми факторами считаются история работ режиссёра и жанр фильма.

Наблюдения показывают, что фильмы в жанре action часто демонстрируют хорошие кассовые результаты даже при более низких оценках IMDb. В то же время комедии или эмоциональные драмы, несмотря на потенциально более высокие оценки IMDb, могут не достигать сопоставимых кассовых результатов.

Эти наблюдения подчёркивают сложное взаимодействие характеристик фильма и предпочтений аудитории, что побуждает уделять большее внимание таким факторам, как история режиссёра и жанровая принадлежность.

C. Обзор

В проекте используется структурированная методология построения и оценки прогностической модели. Сначала собирается большой датасет фильмов и их характеристик из разных источников, после чего данные подготавливаются под задачу прогнозирования.

Затем выполняется предварительная обработка данных: обработка пропущенных значений, выбросов и категориальных переменных. Проводится анализ данных для изучения их структуры, характеристик и взаимосвязей. Используются описательная статистика, выводная статистика и методы визуализации, включая графики сравнения качества моделей на обучающей и тестовой выборках.

После этого выбираются алгоритмы машинного обучения, подходящие для задачи регрессии, например деревья решений и случайные леса. Модели обучаются и тестируются с использованием кросс-валидации, а их качество сравнивается по метрикам R^2 и Mean Squared Logarithmic Error. Также применяются методы улучшения моделей: настройка гиперпараметров, отбор признаков и регуляризация. Полученная модель может использоваться для прогнозирования выручки фильма на основе его характеристик.

II. Обзор литературы

В этом разделе рассматриваются определения Principal Component Analysis (PCA), Label Encoder, Standard Scaler, SelectKBest, GridSearchCV, Train Test Split, а также кратко описываются модели, используемые в проекте. Кроме того, объясняются метрики оценки R^2 score и MSLE.

Principal Component Analysis (PCA)

PCA — это статистическая процедура, использующая ортогональное преобразование для перевода набора наблюдений возможно коррелированных переменных в набор значений линейно некоррелированных переменных, называемых главными компонентами. Этот метод применяется для выделения вариативности и обнаружения выраженных закономерностей в датасете.

Label Encoder

Label Encoder — это метод преобразования категориальных данных в числовой формат. Он присваивает каждой уникальной категории целочисленное значение, делая данные пригодными для алгоритмической обработки.

Standard Scaler

StandardScaler — это метод предварительной обработки, используемый для стандартизации признаков путём вычитания среднего и масштабирования к единичной дисперсии. После преобразования распределение признака имеет среднее значение 0 и стандартное отклонение 1. Такая стандартизация особенно полезна для алгоритмов машинного обучения, предполагающих, что признаки центрированы около нуля и имеют сопоставимую дисперсию.

SelectKBest Features

SelectKBest — это метод отбора признаков в Scikit-Learn. Он выбирает признаки с k наивысшими значениями заданной `scoring`-функции. Иными словами, он позволяет выбрать k лучших признаков в датасете, где k задаётся пользователем.

GridSearchCV

GridSearchCV — это функция из пакета `sklearn.model_selection`. Она перебирает заранее заданные гиперпараметры и обучает `estimator` на обучающей выборке. Также можно задать число повторений кросс-валидации для каждой комбинации гиперпараметров.

Train Test Split

Функция `train_test_split` из `sklearn.model_selection` делит датасет на случайные обучающую и тестовую подвыборки. Эти подвыборки не пересекаются, поэтому один и тот же объект не может присутствовать одновременно в обеих частях. Это позволяет обучить модель на одной части данных

и проверить её на другой. В проекте используется разбиение 80/20 для обучения и тестирования моделей.

Модели

A. Linear Regression

Линейная регрессия — статистический подход к моделированию связи между зависимой переменной и одной или несколькими независимыми переменными.

B. Decision Trees

Дерево решений — модель поддержки принятия решений, использующая древовидную структуру решений и их возможных последствий. Это способ представления алгоритма, содержащего условные управляющие конструкции.

C. Gradient Boosting

Gradient Boosting — метод машинного обучения для задач регрессии и классификации, который строит ансамбль слабых моделей, обычно деревьев решений.

D. Bagging

Bootstrap Aggregating, или Bagging, — метаалгоритм, предназначенный для повышения стабильности и точности моделей машинного обучения в задачах классификации и регрессии. Он снижает дисперсию и помогает избегать переобучения.

E. Random Forests

Random Forests — метод машинного обучения, который строит множество деревьев решений во время обучения и выдаёт результат на основе класса большинства деревьев для классификации или среднего прогноза деревьев для регрессии.

F. XGBoosting

XGBoost — оптимизированная библиотека распределённого градиентного бустинга, разработанная для высокой эффективности, гибкости и переносимости. Она реализует алгоритмы машинного обучения в рамках Gradient Boosting. Основные преимущества XGBoost:

- параллелизация: XGBoost поддерживает параллельное обучение на больших датасетах с использованием нескольких CPU-ядер или GPU;
- регуляризация: XGBoost включает L1- и L2-регуляризацию для предотвращения переобучения и повышения обобщающей способности модели;
- обработка пропущенных данных: XGBoost может автоматически работать с пропусками без дополнительной импутации.

Метрики оценки

R^2 Score

R^2 score, или коэффициент детерминации, — статистическая мера, показывающая долю дисперсии зависимой переменной, объясняемую независимыми переменными в регрессионной модели. Эта метрика показывает качество подгонки модели и то, насколько хорошо модель может предсказывать новые наблюдения.

Mean Squared Logarithmic Error (MSLE)

Mean Squared Logarithmic Error (MSLE) — статистическая мера оценки точности регрессионных моделей, особенно полезная, когда целевая переменная имеет экспоненциальный рост или когда

данные содержат выбросы. MSLE вычисляется как среднее значение квадратов разностей между логарифмом предсказанных значений и логарифмом фактических значений. Метрика показывает относительную ошибку между прогнозами и реальными значениями и сильнее штрафует недооценку, чем переоценку. Чем ниже MSLE, тем лучше модель соответствует данным. Например, $MSLE = 0.1$ означает, что в логарифмической шкале предсказания модели в среднем отклоняются от фактических значений примерно на 10%.

III. Выбор датасета

A. Изменение стратегии формирования датасета

В первоначальном варианте был создан пользовательский датасет путём объединения четырёх отдельных наборов данных: Movies Industry Dataset, IMDb 5000 Movies Multiple Genres Dataset, IMDb 5000 Movies Dataset и Top 500 Movies Budget. Объединение выполнялось последовательно, в результате чего был получен датасет из 7118 фильмов с входными переменными, такими как бюджет, режиссёр, жанр, ведущая команда, рейтинги IMDb, а выходной переменной являлась кассовая выручка.

Однако в процессе работы возникла необходимость отойти от первоначально предложенных датасетов. Был выбран уточнённый датасет, основанный только на Movies Industry Dataset, с исключением записей, содержащих пропущенные значения. Это решение было принято по причинам, описанным ниже.

B. Обоснование перехода к другому датасету

Основной проблемой первоначально сформированного датасета было недостаточно хорошее качество работы прогностических моделей, выражавшееся в более низкой точности. Это было связано с тем, что входные переменные были выбраны без достаточно глубокого анализа доступных данных. В результате датасеты подгонялись под заранее заданное представление о факторах выручки, что снижало качество итогового набора данных. Кроме того, фильмы с похожими названиями могли приводить к путанице при объединении датасетов, что также усложняло процесс.

С учётом этих проблем методология была пересмотрена. Был проведён более глубокий анализ данных, связанных с прогнозированием выручки фильмов, что позволило лучше структурировать датасет для обучения модели, способной надёжно прогнозировать доходы.

C. Преимущества оптимизированного датасета

Дальнейший поиск подходящего датасета привёл к Movies Dataset, который соответствовал критериям проекта. Надёжность датасета была повышена за счёт удаления записей с null-значениями перед подачей данных в модели.

Важное преимущество текущего датасета заключается в том, что он устраняет ограничения предыдущих данных. Он включает дополнительные входные переменные, такие как год, производственная компания и количество голосов вместе с IMDb score. Эти признаки повышают точность модели машинного обучения при прогнозировании выручки фильмов. Кроме того, использование одного источника данных устранило лишний шум, который возникал при объединении нескольких датасетов.

IV. Анализ данных

Таблица 1. Описание признаков датасета фильмов

Признак	Описание
Name	Название фильма
Rating	Возрастной рейтинг фильма
Genre	Жанр фильма
Year	Год выхода фильма
Released	Дата выхода фильма
Score	Рейтинг IMDb
Votes	Количество голосов, полученных фильмом
Director	Режиссёр фильма
Writer	Автор сценария
Star	Главный актёр или актриса
Country	Страна производства фильма
Budget	Бюджет фильма
Company	Производственная компания
Runtime	Длительность фильма

На этапе анализа данных был подробно изучен собранный датасет фильмов, чтобы получить представление о его структуре, распределении и связях между признаками и целевой переменной — выручкой фильма. Использовались описательная статистика, выводная статистика и методы визуализации.

A. Описательная статистика

Для числовых признаков, таких как бюджет и рейтинги, были рассчитаны среднее, медиана, стандартное отклонение, минимум, максимум и квартили. Это позволило получить общее представление о центральной тенденции и разбросе данных.

B. Выводная статистика

Были проведены статистические проверки для анализа взаимосвязей между признаками и целевой переменной. Например, корреляционный анализ использовался для оценки силы и направления связи между числовыми признаками и выручкой.

V. Предварительная обработка

A. Параметры датасета

В датасете используется 14 параметров, включающих числовые и нечисловые типы данных:

1. name; 2. rating; 3. genre; 4. year; 5. released; 6. score; 7. votes; 8. director; 9. writer; 10. star; 11. country; 12. budget; 13. company; 14. runtime.

К нечисловым типам относятся 9 параметров:

1. name; 2. rating; 3. genre; 4. released; 5. director; 6. writer; 7. star; 8. country; 9. company.

Для подготовки данных к регрессионным моделям нечисловые признаки необходимо закодировать в числовые метки. Для этой цели используется LabelEncoder из scikit-learn.

B. Обработка null-значений

В Movie Industry Dataset содержится 2247 null-значений по 11 параметрам при общем размере 7669 записей. Поскольку budget и gross являются ключевым параметром и выходной переменной, записи с пропусками в этих полях были удалены. После этого осталось 5422 записи.

C. PCA

Была предпринята попытка использовать Principal Component Analysis, однако значительного увеличения точности добиться не удалось. Предполагается, что причина заключается в том, что PCA более эффективно работает при большем количестве параметров и данных. Особенно полезным этот метод может быть в задачах регрессии или классификации изображений и звука, где важна размерность данных. Поэтому PCA было решено исключить из preprocessing.

D. Лучшие признаки

Было необходимо определить, какие признаки вносят наибольший вклад в выручку фильма. Для этого использовался SelectKBest, после чего были оценены все 8668 признаков.

Так как признаков было много, отдельно были выведены только признаки со score больше 100. Согласно ожиданиям, наиболее значимым признаком оказался бюджет со score около 6569. Однако неожиданно вторым по значимости оказалось количество голосов. Кроме того, runtime, year и score также сыграли заметную роль в прогнозировании выручки.

Также было выявлено, что некоторые отдельные компании и специалисты в области режиссуры, актёрского состава и производства влияли на кассовые результаты фильмов. В целом можно заметить тенденцию, что фильмы с рейтингами PG-13 и R показывают хорошие результаты. Жанры Action, Animation и Comedy также связаны с повышением выручки фильма.

E. Масштабирование признаков

Улучшенная предварительная обработка признаков реализована в `feature_scaling.py`:

- логарифмическое преобразование для скошенных числовых признаков, особенно бюджета и выручки;
- Standard Scaler для нормализации числовых признаков;
- Label Encoder для кодирования категориальных значений и преобразования текстовых категорий в числовой формат.

F. Feature Engineering

В моделях создаются новые признаки:

- `vote_score_ratio`;
- `budget_year_ratio`;
- `vote_year_ratio`;
- `score_runtime_ratio`;
- `budget_per_minute`;
- `votes_per_year`;
- `is_recent`;
- `is_high_budget`;
- `is_high_votes`;
- `is_high_score`.

Эти признаки отражают сложные зависимости и тренды в данных, улучшая способность модели находить закономерности. Сочетание ratio-признаков и бинарных признаков даёт более богатое представление характеристик фильма и повышает качество прогнозирования разных моделей.

G. Влияние на точность модели

Использование этих методов preprocessing и feature engineering значительно повысило точность моделей. За счёт обработки дисбалансов данных и выявления более тонких зависимостей удалось существенно снизить относительные ошибки и получить более надёжные прогнозы выручки для заинтересованных сторон киноиндустрии.

VI. Выбор модели

Для прогнозирования выручки фильмов были рассмотрены несколько регрессионных методов и ансамблевых подходов: Linear Regression с PCA и без PCA, Decision Trees, Gradient Boosting, Bagging, Random Forests и XGBoosting. Ансамблевые методы, такие как Random Forests и Gradient Boosting, способны учитывать сложные взаимодействия и нелинейности в данных.

1. Linear Regression: изначально использовалась для изучения линейных зависимостей в датасете и проверки того, может ли линейная модель адекватно описать данные. 2. Gradient Boosting: применялся как прогностический метод для создания ансамбля слабых моделей, обычно деревьев решений. Каждый следующий learner исправляет ошибки предыдущих. Gradient Boosting известен устойчивостью к переобучению. 3. Random Forest: использовался как ансамблевый метод. Random Forest строит множество деревьев решений и делает прогноз на основе их совокупного результата. Несмотря на попытки уменьшить размерность данных, модель Random Forest переобучалась на train-set и не показала существенного превосходства над другими моделями. 4. Decision Tree: использовалось как иерархическая модель поддержки решений. Деревья решений представляют решения и их последствия в древовидной структуре и дают понятную визуализацию процесса принятия решений. 5. Bagging: использовался для повышения качества модели путём обучения нескольких моделей на случайных подвыборках исходных данных. Результаты объединяются для получения более точного и устойчивого прогноза. 6. XGBoost: применялся как популярный алгоритм ансамблевого обучения. XGBoost эффективен для supervised learning задач, включая регрессию и классификацию. Он итеративно строит модель, объединяя прогнозы нескольких отдельных моделей, часто деревьев решений.

VII. Улучшение модели

Для повышения качества модели были использованы несколько стратегий.

A. Настройка гиперпараметров с использованием GridSearchCV

GridSearchCV — мощный инструмент, выполняющий полный перебор заданных значений параметров для estimator. В проекте используется Gradient Boosting Regressor с функцией потерь squared error. Процесс выглядит следующим образом:

- задаётся словарь `param_grid`, содержащий различные гиперпараметры, например число estimators, максимальную глубину и learning rate;
- GridSearchCV систематически проверяет различные комбинации гиперпараметров с использованием кросс-валидации, в данном случае 5-fold cross-validation;
- лучшая комбинация параметров определяется по наибольшему R^2 score и извлекается через `best_params`;
- на основе оптимальных параметров инициализируется финальная модель;
- модель обучается на training data и оценивается на training и test datasets для проверки точности.

Такой процесс направлен на создание устойчивой и качественной модели.

B. Реализация XGBRegressor с использованием библиотеки xgboost

XGBoost (Extreme Gradient Boosting) — мощная и эффективная реализация алгоритма градиентного бустинга, широко применяемая для задач машинного обучения, включая регрессию и классификацию. В проекте использовался XGBRegressor из библиотеки xgboost для обучения и тестирования регрессионной модели прогнозирования выручки фильмов на основе признаков, таких как дата выхода, жанр, режиссёр и другие.

Для обучения и оценки XGBoost regression model были выполнены следующие шаги:

1. загрузка датасета фильмов и предварительная обработка данных с кодированием категориальных признаков через LabelEncoder из scikit-learn; 2. разделение датасета на training и testing sets с помощью train_test_split; 3. определение custom callback class TrackR2Score, наследуемого от xgb.callback.TrainingCallback; этот класс переопределяет метод after_iteration для расчёта и сохранения R^2 score на training set после каждой итерации обучения; 4. настройка гиперпараметров с помощью GridSearchCV; callback TrackR2Score передаётся в XGBRegressor, используемый как estimator в GridSearchCV, что позволяет отслеживать R^2 score во время grid search; 5. обучение финальной модели XGBRegressor с лучшими гиперпараметрами, найденными GridSearchCV; 6. оценка качества модели на training и testing sets с помощью метрик R^2 score и Mean Absolute Percentage Error (MAPE); 7. визуализация фактических и предсказанных значений для training и testing sets; 8. построение графика training R^2 score для наблюдения постепенного улучшения модели во время обучения.

Использование библиотеки XGBoost и custom callback позволило эффективно обучить и оценить регрессионную модель для прогнозирования выручки фильмов, одновременно отслеживая качество модели в процессе обучения.

VIII. Оценка модели

Качество моделей оценивается с использованием Mean Squared Logarithmic Error (MSLE) и Coefficient of Determination (R^2). В совокупности эти две метрики дают комплексное представление о работе модели. R^2 показывает, насколько хорошо модель улавливает закономерности в данных, а MSLE показывает относительную ошибку прогнозов и менее чувствительна к выбросам, что полезно для данных с экспоненциальным характером роста, например бюджета и выручки.

Таблица II. Результаты оценки моделей

Модель	Выборка	R^2	MSLE
Linear Regression	Training Set	0.6181	0.0053
Linear Regression	Testing Set	0.6520	0.0051
Decision Tree	Training Set	0.8310	0.0024
Decision Tree	Testing Set	0.5994	0.0059
Bagging	Training Set	0.8380	0.0023
Bagging	Testing Set	0.7105	0.0042
Gradient Boost	Training Set	0.8750	0.0016
Gradient Boost	Testing Set	0.7350	0.0040
XG Boost	Training Set	0.8633	0.0018
XG Boost	Testing Set	0.7402	0.0041
Random Forest	Training Set	0.8475	0.0022
Random Forest	Testing Set	0.7235	0.0041

IX. Пользовательские интерфейсы для прогнозирования выручки фильмов

Были разработаны два пользовательских интерфейса для доступа к модели прогнозирования выручки фильмов: Command Line Interface (CLI) и Streamlit Web Application. Оба интерфейса позволяют пользователям вводить 14 ключевых параметров, на которых была обучена модель XGBoost, известная своей точностью и скоростью.

A. Command Line Interface (CLI)

CLI доступен через `main.py`. Пользователь может запустить `python main.py` и ввести необходимые параметры для прогнозирования выручки будущего фильма.

B. Streamlit Web Application

Для пользователей, предпочитающих графический интерфейс, было создано Streamlit web application. Оно предоставляет ту же функциональность, что и CLI, но в более наглядном интерактивном формате.

C. Категории прогнозируемой выручки

Оба интерфейса предоставляют оценки выручки в долларах США в следующих диапазонах:

- Low Revenue: 10M или меньше;
- Medium-Low Revenue: 10M - 40M;
- Medium Revenue: 40M - 70M;
- Medium-High Revenue: 70M - 120M;
- High Revenue: 120M - 200M;
- Ultra High Revenue: 200M или больше.

Такая категоризация позволяет быстро оценить потенциальные финансовые результаты фильма на основе введенных параметров.

X. Заключение

В результате комплексного анализа моделей прогнозирования выручки фильмов Gradient Boosting и XGBoost показали наилучшие результаты, продемонстрировав высокие значения R^2 и очень низкий Mean Squared Logarithmic Error (MSLE). Эти результаты подтверждают устойчивость и точность выбранного подхода.

Была успешно решена исходная цель проекта: предоставить заинтересованным сторонам доступное программное средство для точного прогнозирования выручки фильмов. Модель стабильно помещает прогнозы в корректный диапазон выручки с достаточно высокой уверенностью и в соседние диапазоны с высокой надёжностью. Модель может служить полезным инструментом для создателей фильмов, предоставляя информацию для поддержки принятия решений в сложной области производства и финансирования кино.

В дальнейшем планируется улучшать качество и обобщающую способность моделей. Для этого предполагается расширить обучающий датасет, включив более разнообразные и объёмные данные. Такой подход повысит устойчивость моделей и позволит им лучше обобщаться на широкий спектр сценариев в динамичной среде киноиндустрии.

Список литературы

1. Vr, Nithin & Pranav, M & Babu, PB & Lijiya, A. (2014). Predicting Movie Success Based on IMDB Data. International Journal of Business Intelligents. 003. 34-36. 10.20894/IJBI.105.003.002.004. 2. Pradeep, Kavya & TintuRosmin, C & Durom, Sherly & Anisha, G. (2020). Decision Tree Algorithms for Accurate

Prediction of Movie Rating. 853-858. 10.1109/ICCMC48092.2020.ICCMC-000158. 3. Garima Verma and Hemraj Verma, "Predicting Bollywood Movies Success Using Machine Learning Technique," IEEE, 2019. 4. Rijul Dhir and Anand Raj, "Movie Success Predictions using Machine Learning and their Comparison," IEEE International Conference on Secure Cyber Computing and Communication, 2018. 5. Ashutosh Kanitar, "Bollywood Movie Success Prediction using Machine Learning Algorithms," IEEE Third International Conference on Circuits, Control, Communication and Computing, 2018. 6. Wales, Lorene. (2017). The Complete Guide to Film and Digital Production: The People and the Process. 10.4324/9781315294896. 7. Beyza Cizmeci and Sule Gunduz Oguducu, "Predicting IMDb Rating of Pre-release Movies with Factorization Machines Using Social Media," IEEE 3rd International Conference on Computer Science and Engineering, 2018. 8. Steve Shim and Mohammad Pourhomayoun, "Predicting Movie Market Revenues Using Social Media Data," IEEE International Conference on Information Reuse and Integration, 2017. 9. Nahid Quader and Md. Osman Gani, "A Machine Learning Approach to Predict Movie Box-office," Information Technology (ICCIT), December 2017. 10. Beyza Cizmeci and Sule Gunduz Oguducu, "Predicting IMDb Ratings of Pre-release Movies with Factorization Machines Using Social Media," International Conference of Computer and Information Technology (ICCIT), 2017. 11. Subramaniaswamy V. and Vignesh Vaibhav M., "Predicting Movie Box Office Success using Multiple Regression and SVM," International Conference of Computer and Information Technology (ICCIT), 2017. 12. M.H. Latif, H. Afzal, "Prediction of Movies Popularity Using Machine Learning Techniques," National University of Sciences and Technology, H-12, ISB, vol. 16, no. 8, pp. 127-131, 2016. 13. D.A. Olubukola, O.M. Stephen, A.K. Funmilayo, Omotunde Ayokunle, A. Oyebola, A. Oduroye, Wumi Ajayi, Yaw Mensah. (2021). Movie Success Prediction Using Data Mining. British Journal of Computer, Networking and Information Technology. 4. 22-30. 10.52589/BJCNIT-CQOCIREC.